

Sprawozdanie 3

Marta Hałas

2026-01-27

Spis treści

1	Lista 9	3
1.1	Przygotowanie danych i założenie o rozkładzie	3
1.2	Zadanie 1	3
1.3	Zadanie 2	5
1.4	Zadanie 3	5
1.5	Zadanie 4	6
1.6	Zadanie 5	6
1.7	Zadanie 6	7
1.8	Zadanie 7	7
1.9	Zadanie 8	9
1.10	Zadanie 9	10
2	Lista 10	10
2.1	Zadanie 1	10
2.2	Zadanie 2	11
2.3	Zadanie 3	12
2.4	Zadanie 4	14
2.4.1	Wyprowadzenie do podpunktów a) i b).	14
2.4.2	a)	14
2.4.3	b)	15
2.5	Zadanie 5	17
2.5.1	Wyprowadzenie do podpunktów a) i b).	17
2.5.2	a)	18
2.5.3	b)	18
2.6	Zadanie 6	20

3	Lista 11	21
3.1	Zadanie 1	21
3.2	Zadanie 2	22
3.3	Zadanie 3	22
3.4	Zadanie 4	23
3.5	Zadanie 5	25
3.6	Zadanie 6	25
4	Lista 12	26
4.1	Zadanie 1	26
4.1.1	a)	26
4.1.2	b)	27
4.1.3	c)	28
4.2	Zadanie 2	28
4.2.1	a)	28
4.2.2	b)	29
4.2.3	c)	30
5	Zadania dodatkowe	30
5.1	Zadanie 3 z listy 12	30
5.1.1	a)	30
5.1.2	b)	32
5.1.3	c)	33
5.2	Zadanie 4 z listy 12	34
5.2.1	a)	34
5.2.2	b)	36
5.2.3	c)	37
5.3	Zadanie dodatkowe z listy 12	38
5.4	Zadanie dodatkowe z dodatkowej listy	40
5.4.1	Zadanie 1	40

1 Lista 9

1.1 Przygotowanie danych i założenie o rozkładzie

Przeprowadzam następujące modyfikacje:

- Wybieram kolumny sprecyzowane w poleceniu
- Usuwam brakujące dane
- Centruje “age” oraz “ph.karno”
- Zamieniam typ “sex” oraz “ph.ecog” na faktor

```
data = lung
data = data[, c("status", "time", "age", "sex", "ph.ecog", "ph.karno")]
data = na.omit(data)
age_mean = mean(data$age)
data$age = data$age - age_mean
ph.karno_mean = mean(data$ph.karno)
data$ph.karno = data$ph.karno - ph.karno_mean
data$sex = as.factor(data$sex)
data$ph.ecog = as.factor(data$ph.ecog)
attach(data)
```

Na tej liście zadań korzystamy z parametrycznych modeli w oparciu o założenie, że dane pochodzą z rozkładu

$$We(\alpha, \lambda).$$

1.2 Zadanie 1

Model liniowy logarytmu czasu w funkcji survreg() jest postaci:

$$\ln(T) = \mu + \gamma^T z + \sigma \varepsilon,$$

gdzie:

- T to czas życia
- μ, σ, γ to parametry modelu
- ε to reszta o określonym rozkładzie (w naszym wypadku wartości ekstremalnej, bo wybieramy, że T ma rozkład Weibulla)

```
fit_aft = survreg(Surv(time, status) ~
                  sex +
                  age +
                  ph.ecog +
                  ph.karno,
                  data = data,
                  dist = "weibull")

gamma = fit_aft$coefficients[2:7]
mu = fit_aft$coef[1]
sigma = fit_aft$scale

gamma
```

```
##          sex2          age      ph.ecog1      ph.ecog2      ph.ecog3      ph.karno
## 0.408280141 -0.008601783 -0.421560818 -0.926113456 -1.687243371 -0.010056702
```

```
mu
```

```
## (Intercept)
##      6.30118
```

```
sigma
```

```
## [1] 0.7206529
```

```
beta = -as.numeric(gamma)
mu = as.numeric(mu)
sigma = as.numeric(sigma)
```

Chcemy przedstawić model w postaci z wykładu:

$$S(x|z) = S_0(\exp(\beta^T z)x),$$

gdzie:

$$\beta = -\gamma$$

```
beta = -as.numeric(gamma)
```

Z dokładnością do dwóch cyfr znaczących mamy:

$$\beta = (-0.41, 0.0086, 0.42, 0.93, 1.69, 0.01),$$

w postaci:

$$\beta = (sex2, age, ph.ecog1, ph.ecog2, ph.ecog3, ph.karno).$$

Zmienne age oraz ph.karno mają zwykły typ numeryczny, natomiast pozostałe są indykatorami. Np. dla osoby z ph.ecog=3 podamy ph.ecog3=1 oraz ph.ecog1=ph.ecog2=0.

Odczytujemy parametry rozkładu Weibulla:

$$\lambda = \exp(-\mu/\sigma),$$

$$\alpha = 1/\sigma$$

```
lambda = exp(-mu/sigma)
alpha = 1/sigma
```

```
lambda
```

```
## [1] 0.0001594611
```

```
alpha
```

```
## [1] 1.387631
```

Z dokładnością do dwóch cyfr znaczących mamy:

$$\lambda = 0.00016,$$

$$\alpha = 1.4,$$

1.3 Zadanie 2

Jeśli z_1 oraz z_2 są wektorami cech, to dla $\beta^T(z_1 - z_2) > 0$, osoba z z_1 ma w każdej chwili większe prawdopodobieństwo śmierci niż osoba z z_2 . Patrząc na znaki wartości w wektorze β mamy, że:

- bycie kobietą wydłuża czas życia
- wysokie wartości ph.ecog, ph.karno oraz podeszły wiek skracają czas życia
- współczynniki dla wieku oraz ph.karno są bliskie zeru

Jedyną zaskakującą obserwacją jest to, że ph.karno skracza czas życia.

1.4 Zadanie 3

Implementujemy oszacowanie funkcji przeżycia korzystając z faktu podanego na wykładzie:

$$S(x|z) = \exp(-\lambda \exp(\alpha \beta^T z) x^\alpha)$$

```
aft_S = function(x, z) exp(-lambda*exp(alpha*sum(beta*z))*x^alpha)
```

Obliczamy szacowane prawdopodobieństwo przeżycia 300 dni dla kobiety w wieku 70 lat o charakterystyce ph.ecog=1 i ph.karno=90.


```
z = c(1, 70 - age_mean, 1, 0, 0, 90 - ph.karno_mean)
x = 300
aft_S(x,z)
```

```
## [1] 0.5806085
```

W przybliżeniu wynosi ono 0.58.

1.5 Zadanie 4

Oszacowanie funkcji przeżycia w modelu ATF na danych lung, dla kobiety w wieku 70 lat o charakterystyce `ph.ecog=1` i `ph.karno=90`.



Rysunek 1: Oszacowanie funkcji przeżycia w modelu ATF na danych lung dla kobiety w wieku 70 lat o charakterystyce `ph.ecog=1` i `ph.karno=90`.

Z wykresu 1 możemy odczytać np. że prawdopodobieństwo przeżycia 350 dni dla osoby o sprecyzowanej w tytule charakterystyce wynosi około 0.5.

1.6 Zadanie 5

Model proporcjonalnych hazardów jest postaci

$$h(x|z) = h_0(x) \exp(\beta^T z).$$

Można pokazać, że

$$S(x|z) = S_0(x) \exp(\beta^T z).$$

Dopasowuję teraz model oraz odczytuję parametry:

```
ph_fit = phreg(Surv(time, status) ~  
               sex +  
               age +  
               ph.ecog +  
               ph.karno,
```

```

data = data,
dist = "weibull")

beta1 = as.numeric(ph_fit$coefficients[1:6])
scale = as.numeric(exp(ph_fit$coefficients[7]))
shape = as.numeric(exp(ph_fit$coefficients[8]))
lambda1 = scale^(-shape)
alpha1 = shape

```

```
beta1
```

```
## [1] -0.56654199  0.01193610  0.58497067  1.28510332  2.34127043  0.01395499
```

```
lambda1
```

```
## [1] 0.0001594611
```

```
alpha1
```

```
## [1] 1.387631
```

Z dokładnością do dwóch cyfr znaczących otrzymujemy, że:

$$\lambda = 0.00016,$$

$$\alpha = 1.4,$$

$$\beta = (-0.57, 0.012, 0.58, 1.3, 2.3, 0.014).$$

Otrzymujemy nieco inne wartości niż w modelu AFT, jednak zauważamy pewne podobieństwa:

- te same znaki współczynników
- wartości bliskie zeru dla wieku oraz ph.karno

1.7 Zadanie 6

Ze względu na podobne wartości, wpływ cech na prognozy pozostaje taki sam jak w modelu AFT. Z drugiej strony, tym razem możemy powiedzieć, że jeśli z_1 oraz z_2 są wektorami cech, to:

$$\frac{h(x|z_1)}{h(x|z_2)} = \exp(\beta^T(z_1 - z_2)),$$

czyli funkcje hazardu są proporcjonalne. Jeśli $\beta^T(z_1 - z_2) > 0$ to osoba o charakterystyce z_1 ma większą funkcję hazardu, czyli krótszy czas życia.

1.8 Zadanie 7


Implementujemy funkcje hazardu:

```
ph_h0 <- function(t) alpha1 * lambda1 * t ^ (alpha1-1)
ph_h <- function(t, z) ph_h0(t) * exp(sum(beta1*z))
```

Wczytujemy wektory cech:


```
z1 = c(1, 70 - age_mean, 1, 0, 0, 90 - ph.karno_mean)
z2 = c(1, 70 - age_mean, 0, 1, 0, 90 - ph.karno_mean)
```

Oszacowanie logarytmowanej funkcji hazardu w modelu proporcjonalnych hazardów na danych lung, dla kobiety w wieku 70 lat o charakterystyce ph.karno=90



Rysunek 2: Oszacowanie funkcji hazardu w modelu proporcjonalnych hazardów na danych lung, dla kobiety w wieku 70 lat o charakterystyce ph.karno=90

Oszacowanie funkcji hazardu w modelu proporcjonalnych hazardów na danych lung, dla kobiety w wieku 70 lat o charakterystyce $ph.karno=90$



Rysunek 3: Oszacowanie logarytmicznej funkcji hazardu w modelu proporcjonalnych hazardów na danych lung, dla kobiety w wieku 70 lat o charakterystyce $ph.karno=90$

Na wykresach 2 oraz 3 zauważamy, że krzywa funkcji hazardu dla $ph.ecog=1$ jest ściśle mniejsza niż ta dla $ph.ecog=2$. Jest to zgodne z intuicją (mniejsze wartości $ph.ecog$ oznaczają wyższą sprawność danej osoby). Nie daje nam to powodów do uznania modelu za nieodpowiedni. Proporcjonalne wartości na wykresie logarytmicznym powinny być przesunięte względem siebie o stałą, co obserwujemy na wykresie 3.

1.9 Zadanie 8

Korzystając ze wzorów z zadania 5, Wyznaczamy oszacowanie warunkowej funkcji przeżycia:

```
ph_S0 = function(x) exp(-lambda1*x^alpha1)
ph_S = function(x, z) ph_S0(x)^exp(sum(beta1*z))
```

Używamy powyższej funkcji do oszacowania prawdopodobieństw przeżycia 300 dni:

```
ph_S(x, z1) #ph.ecog = 1
```

```
## [1] 0.5806085
```


```
ph_S(x, z2) #ph.ecog = 2
```

```
## [1] 0.3345465
```

Dla $ph.ecog=1$ oraz $ph.ecog=2$ wynoszą one odpowiednio około 0.58 oraz 0.33. Mogliśmy się tego spodziewać, ponieważ niższe $ph.ecog$ oznacza lepszy stan zdrowia. W dokładności, którą posługuje się R, wynik dla $ph.ecog=1$ jest identyczny w modelach PH oraz, wyznaczonym w zadaniu 3, AFT.

1.10 Zadanie 9

Porównanie oszacowań funkcji przeżycia w modelach ATF oraz PH na danych lung, dla kobiety w wieku 70 lat o charakterystyce $ph.ecog=1$ i $ph.karno=90$



Rysunek 4: Porównanie oszacowań funkcji przeżycia w modelach ATF oraz PH na danych lung, dla kobiety w wieku 70 lat o charakterystyce $ph.ecog=1$ i $ph.karno=90$

Z wykresu 4 odczytujemy, że funkcje przeżycia dla obu modeli pokrywają się niemal idealnie.

2 Lista 10

2.1 Zadanie 1

```
model<-coxph(formula=Surv(time,status==2)~age+sex+ph.ecog+ph.karno, data=data)
```

```
model$coeff
```

Poniżej w tabeli 1 znajdują się oszacowane parametry modelu proporcjonalnych hazardów Coxa opisanego w poleceniu zadania.

Tabela 1: Współczynniki modelu

Wartości współczynników modelu	
age	0.013
sex2	-0.566
ph.ecog1	0.578
ph.ecog2	1.240
ph.ecog3	2.396
ph.karno	0.012

2.2 Zadanie 2

Zgodnie z definicją

$$h_z(t) = h_0(t) \exp(0.013 \cdot \text{age} - 0.566 \cdot \text{sex2} + 0.578 \cdot \text{ph.ecog1} + 1.24 \cdot \text{ph.ecog2} + 0.2396 \cdot \text{ph.ecog3} + 0.012 \cdot \text{ph.karno})$$

Każdy z współczynników będziemy interpretować z założeniem, że pozostałe zmienne są stałe.

Interpretacja współczynnika *age*.

Niech $h_0(t)$ oznacza funkcję hazardu jednostki o zerowym wektorze charakterystyk, czyli w rozważanym przypadku - funkcję hazardu pacjenta z grupy zerowej. W tym przypadku o danym wieku bazowym. $h_1(t)$ oznacza funkcję hazardu pacjenta o rok starszego, od tego w wieku bazowym.

$$h_1(t) = h_0(t) \exp(0.013) > h_0(t), \quad t \in \mathbb{R}$$

Funkcje przeżycia $S_0(t), S_1(t)$ oznaczają odpowiednio funkcję przeżycia pacjenta, w danym wieku i o rok starszego

$$S_1(t) = [S_0(t)^{\exp(0.013)}] < S_0(t)$$

Przy reszcie stałych zmiennych wzrost wieku pacjenta o 1 rok zwiększa wartość funkcji hazardu, a zatem zmniejsza wartość funkcji przeżycia w porównaniu z pacjentem w wieku bazowym.

Interpretacja współczynnika *sex2*

Niech $h_0(t)$ oznacza funkcję hazardu jednostki o zerowym wektorze charakterystyk, czyli w rozważanym przypadku - funkcję hazardu pacjenta z grupy zerowej. W tym przypadku pacjent jest płci męskiej. $h_1(t)$ oznacza funkcję hazardu pacjenta płci żeńskiej.

$$h_1(t) = h_0(t) \exp(-0.566) < h_0(t), \quad t \in \mathbb{R}$$

Funkcje przeżycia $S_0(t), S_1(t)$ oznaczają odpowiednio funkcję przeżycia pacjenta, płci męskiej i płci żeńskiej.

$$S_1(t) = [S_0(t)^{\exp(-0.566)}] > S_0(t)$$

Przy reszcie stałych zmiennych wartości funkcji hazardu pacjenta płci żeńskiej jest mniejsza, niż wartość funkcji hazardu pacjenta płci męskiej. Zatem zwiększa się wartość funkcji przeżycia pacjenta płci żeńskiej w porównaniu z pacjentem płci męskiej.

Interpretacja współczynnika *ph.ecog*.

Niech $h_0(t)$ oznacza funkcje hazardu jednostki o zerowym wektorze charakterystyk, czyli w rozważanym przypadku - funkcję hazardu pacjenta z grupy zerowej. W tym przypadku o sprawności prawidłowej w skali ECOG według lekarza ($ph.ecog=0$). $h_1(t), h_2(t), h_3(t)$ oznaczają funkcje hazardu pacjenta o gorszej sprawności w tej samej skali ECOG.

$$h_1(t) = h_0(t) \exp(0.578) > h_0(t), \quad t \in \mathbb{R}$$

$$h_2(t) = h_0(t) \exp(1.24) > h_0(t), \quad t \in \mathbb{R}$$

$$h_3(t) = h_0(t) \exp(2.396) > h_0(t), \quad t \in \mathbb{R}$$

Funkcje przeżycia $S_0(t), S_1(t)$ oznaczają odpowiednio pacjenta, o sprawności prawidłowej i trochę gorszej.

$$S_1(t) = [S_0(t)^{\exp(0.578)}] < S_0(t)$$

$$S_2(t) = [S_0(t)^{\exp(1.24)}] < S_0(t)$$

$$S_3(t) = [S_0(t)^{\exp(2.396)}] < S_0(t)$$

Przy reszcie ustalonych stałych zmiennych spadek sprawności pacjenta (wzrost o 1 punkt w skali ECOG) zwiększa wartość funkcji hazardu, a zatem zmniejsza wartość funkcji przeżycia w porównaniu z pacjentem z grupy bazowej o prawidłowej sprawności (0 punktów w skali ECOG) ocenionej przez lekarza.

Interperetacja współczynnika *ph.karno*.

Niech $h_0(t)$ oznacza funkcje hazardu jednostki o zerowym wektorze charakterystyk, czyli w rozważanym przypadku - funkcję hazardu pacjenta z grupy zerowej. W tym przypadku pacjenta o braku jakiegokolwiek sprawności - zgon w skali Karnofsky'ego według lekarza. $h_1(t)$ oznacza funkcję hazardu pacjenta o lepszej sprawności w tej samej skali.

$$h_1(t) = h_0(t) \exp(0.012) > h_0(t), \quad t \in \mathbb{R}$$

Funkcje przeżycia $S_0(t), S_1(t)$ oznaczają odpowiednio pacjenta, o braku sprawności i występowaniu sprawności według lekarza.

$$S_1(t) = [S_0(t)^{\exp(0.012)}] < S_0(t)$$

Przy reszcie ustalonych stałych zmiennych wzrost punktów o 1 w skali Karnofsky'ego zwiększa wartość funkcji hazardu, a zatem zmniejsza wartość funkcji przeżycia w porównaniu z pacjentem o braku sprawności (0 punktów w skali Karnofsky'ego) ocenionej przez lekarza. Nasz model zatem nie odzwierciedla w tym przypadku oczekiwań klinicznych.

2.3 Zadanie 3

Estymator Breslowa bazowej skumulowanej funkcji hazardu

$$\hat{H}_0(t) = \sum_{i: \tau_i \leq t} \frac{1}{\sum_{j \in R(\tau_i)} \exp(\hat{\beta}^T z_j)}$$

Estymator bazowej funkcji przeżycia

$$\hat{S}_0(t) = \exp[-\hat{H}_0(t)]$$

```
model<-coxph(formula=Surv(time,status==2)~age+sex+ph.ecog+ph.karno,data=data)
f_hazardu_bazowa<-basehaz(model, centered=FALSE)
f_przeżycia_bazowa<-exp(-(f_hazardu_bazowa$hazard))
```

Pierwsze 6 oszacowań bazowej skumulowanej funkcji hazardu zostało przedstawionych w tabeli 2 poniżej.

Tabela 2: Pierwsze 6 oszacowań bazowej skumulowanej funkcji hazardu


Wartość	Czas (w dniach)
0.00279	5
0.01123	11
0.01408	12
0.01986	13
0.02278	15
0.02571	26

Pierwsze 6 oszacowań bazowej funkcji przeżycia zostało przedstawionych w tabeli 3 poniżej.

Tabela 3: Pierwsze 6 oszacowań bazowej funkcji przeżycia

Wartość	Czas (w dniach)
0.997	5
0.989	11
0.986	12
0.980	13
0.977	15
0.975	26

Poszczególne oszacowania zaprezentowane na wykresie 5.



Rysunek 5: Wykres oszacowania bazowej skumulowanej funkcji hazardu i bazowej funkcji przeżycia odpowiadającej rozkładowi czasu życia

2.4 Zadanie 4

2.4.1 Wyprowadzenie do podpunktów a) i b).

Funkcja hazardu w modelu Coxa.

$$h_z(t) = h_0(t) \cdot \exp(\beta_1 \cdot age + \beta_2 \cdot ph.ecog + \beta_3 \cdot ph.karno)$$

Estymator Breslowa bazowej skumulowanej funkcji hazardu.

$$\hat{H}_0(t) = \sum_{i: \tau_i \leq t} \frac{1}{\sum_{j \in R(\tau_i)} \exp(\hat{\beta}^T z_j)}$$

Skumulowana funkcja hazardu dla konkretnego pacjenta wyraża się wzorem.

$$\hat{H}(t) = \hat{H}_0(t) \cdot \exp(\hat{\beta}^T z_j)$$

2.4.2 a)


Oszacowanie skumulowanej funkcji hazardu odpowiadającej rozkładowi czasu życia kobiety:

- w wieku 70 lat
- o charakterystyce $ph.ecog=1$

- o charakterystyce ph.karno=90

```
Z<-c(1,70-age_mean,1,0,0,90-ph.karno_mean)
model<-coxph(formula=Surv(time,status==2)~sex+age+ph.ecog+ph.karno,data=data)
f_hazardu_bazowa<-basehaz(model,centered = FALSE)
f_hazardu<-f_hazardu_bazowa$hazard*exp(sum(model$coefficients*Z))
```

Poniższe wykresy 6 przedstawiają wyznaczone powyżej oszacowania dla kobiety w wieku 70 lat o charakterystyce ph.ecog=1 i ph.karno=90.



Rysunek 6: Wykres oszacowania skumulowanej funkcji hazardu oraz logarytmu oszacowania skumulowanej funkcji hazardu odpowiadających rozkładowi czasu życia


2.4.3 b)

Oszacowanie skumulowanej funkcji hazardu odpowiadającej rozkładowi czasu życia kobiety:

- w wieku 70 lat
- o charakterystyce ph.ecog=2
- o charakterystyce ph.karno=90

```
Z<-c(1,70-age_mean,0,1,0,90-ph.karno_mean)
model<-coxph(formula=Surv(time,status==2)~sex+age+ph.ecog+ph.karno,data=data)
f_hazardu_bazowa<-basehaz(model,centered = FALSE)
f_hazardu<-f_hazardu_bazowa$hazard*exp(sum(model$coefficients*Z))
```


Poniższe wykresy 7 przedstawiają wyznaczone powyżej oszacowania dla kobiety w wieku 70 lat o charakterystyce $ph.ecog=2$ i $ph.karno=90$.




Rysunek 7: Wykres oszacowania skumulowanej funkcji hazardu oraz logarytmu oszacowania skumulowanej funkcji hazardu odpowiadających rozkładowi czasu życia

Teraz porównamy nasze wykresy i wysnujemy wnioski co do przyjętego modelu proporcjonalnych hazardów.

Wykres oszacowania skumulowanej funkcji hazardu odpowiadającej rozkładowi czasu życia



Wykres logarytmu oszacowania skumulowanej funkcji hazardu odpowiadającej rozkładowi czasu życia



Rysunek 8: Wykres oszacowania skumulowanej funkcji hazardu oraz logarytmu oszacowania skumulowanej funkcji hazardu odpowiadających rozkładowi czasu życia kobiet o zadanych charakterystykach

Na wykresach 8 oraz zauważamy, że krzywa skumulowanej funkcji hazardu dla $ph.ecog=1$ jest ściśle mniejsza niż ta dla $ph.ecog=2$. Jest to zgodne z intuicją (mniejsze wartości $ph.ecog$ oznaczają wyższą sprawność danej osoby). Proporcjonalne wartości na wykresie logarytmicznym powinny być przesunięte względem siebie o stałą, co obserwujemy na wyresie. Krzywe są do siebie równoległe. Zatem nie daje nam to powodów, wątpliwości do uznania modelu za nieodpowiedni.

2.5 Zadanie 5

2.5.1 Wyprowadzenie do podpunktów a) i b).

Funkcja hazardu w modelu Coxa.

$$h_z(t) = h_0(t) \cdot \exp(\beta_1 \cdot age + \beta_2 \cdot ph.ecog + \beta_3 \cdot ph.karno)$$

Estymator Breslowa bazowej skumulowanej funkcji hazardu.

$$\hat{H}_0(t) = \sum_{i: \tau_i \leq t} \frac{1}{\sum_{j \in R(\tau_i)} \exp(\hat{\beta}^T z_j)}$$

Skumulowana funkcja hazardu dla konkretnego pacjenta wyraża się wzorem.

$$\hat{H}(t) = \hat{H}_0(t) \cdot \exp(\hat{\beta}^T z_j)$$

Funkcja przeżycia odpowiadająca rozkładowi czasu życia.


$$\hat{S}(t) = \exp[-\hat{H}(t)]$$

2.5.2 a)

Oszacowanie funkcji przeżycia (w dniach) odpowiadającej rozkładowi czasu życia kobiety w wieku 70 lat o charakterystyce $ph.ecog=1$ i $ph.karno=90$.

```
Z<-c(1,70-age_mean,1,0,0,90-ph.karno_mean)
model<-coxph(formula=Surv(time,status==2)~sex+age+ph.ecog+ph.karno,data=data)
f_hazardu_bazowa<-basehaz(model,centered = FALSE)
f_hazardu<-f_hazardu_bazowa$hazard*exp(sum(model$coefficients*Z))
f_przeżycia<-exp(-f_hazardu)
```

Poniższy wykres 9 przedstawia powyższe oszacowanie funkcji przeżycia dla kobiety w wieku 70 lat o charakterystyce $ph.ecog=1$ i $ph.karno=90$.



Rysunek 9: Wykres oszacowania funkcji przeżycia pacjenta o zadanej charakterystyce

Szacowane prawdopodobieństwo, że czas życia kobiet o powyżej podanych charakterystykach będzie większy niż 300 dni.

```
czas<-f_hazardu_bazowa$time
indeks<-(which(czas>=300))[1]
f_hazardu<-f_hazardu_bazowa$hazard[indeks]*exp(sum(model$coefficients*Z))
f_przeżycia1<-exp(-f_hazardu)
```

Prawdopodobieństwo to wynosi 0.5901


2.5.3 b)

Oszacowanie funkcji przeżycia (w dniach) odpowiadającej rozkładowi czasu życia kobiety w wieku 70 lat o charakterystyce $ph.ecog=2$ i $ph.karno=90$.

```
Z<-c(1,70-age_mean,0,1,0,90-ph.karno_mean)
model<-coxph(formula=Surv(time,status==2)~sex+age+ph.ecog+ph.karno,data=data)
```

```
f_hazardu_bazowa<-basehaz(model,centered = FALSE)
f_hazardu<-f_hazardu_bazowa$hazard*exp(sum(model$coefficients*Z))
f_przeżycia<-exp(-f_hazardu)
```

Poniższy wykres 10 przedstawia powyższe oszacowanie funkcji przeżycia dla kobiety w wieku 70 lat o charakterystyce ph.ecog=2 i ph.karno=90.



Rysunek 10: Wykres oszacowania funkcji przeżycia pacjenta o zadanej charakterystyce

Szacowane prawdopodobieństwo, że czas życia kobiet o powyżej podanych charakterystykach będzie większy niż 300 dni.

```
czas<-f_hazardu_bazowa$time
indeks<-(which(czas>=300))[1]
f_hazardu<-f_hazardu_bazowa$hazard[indeks]*exp(sum(model$coefficients*Z))
f_przeżycia<-exp(-f_hazardu)
```

Prawdopodobieństwo to wynosi 0.3598

Dla ph.ecog=1 oraz ph.ecog=2 wynoszą one odpowiednio 0.5901, 0.3598. Mogliśmy się tego spodziewać, ponieważ niższe ph.ecog oznacza lepszy stan zdrowia.

Porównanie otrzymanego oszacowania prawdopodobieństwa dla kobiety o charakterystykach opisanych w podpunkcie a) z prawdopodobieństwem otrzymanym w zadaniu 3 oraz 8 z listy 9.

Tabela 4: Porównanie otrzymanych oszacowań prawdopodobieństw


Zadanie	Model	Wartość
Zadanie 5a) lista 10	Cox PH	0.5901
Zadanie 3 lista 9	AFT Weibulla	0.5806
Zadanie 8 lista 9	PH Weibulla	0.5806

Z powyższej tabeli 4 widać, że oszacowanie prawdopodobieństwa na liście 9 w zadaniu 3 (model ATF) i 8 (model PH) jest identyczne. W porównaniu z wartością otrzymaną w zadaniu 5 w podpunkcie a) z listy 10

przy użyciu modelu proporcjonalnych hazardów Coxa zauważamy, że oszacowania otrzymane na liście 9 są mniejsze. Zauważalna różnica jest na drugim miejscu po przecinku. Nie zmienia jednak to faktu, że model wskazuje na niemal takie same prawdopodobieństwa, zatem możemy uznać, że każdy z tych modeli dobrze radzi sobie z danymi.

2.6 Zadanie 6


Wykres 11 przedstawia oszacowaną w zadaniu 5 w podpunkcie a) funkcję przeżycia (w dniach) odpowiadającą rozkładowi czasu życia kobiety w wieku 70 lat o charakterystyce $ph.ecog=1$ i $ph.karno=90$.



Rysunek 11: Wykres oszacowania funkcji przeżycia odpowiadającej rozkładowi czasu życia

Poniżej znajduje się porównanie powyższego wykresu 11 z wykresem otrzymanym w zadaniu 9 na liście 9 4.

Porównanie oszacowań funkcji przeżycia w modelach PH oraz Cox PH na danych lung, dla kobiety w wieku 70 lat o charakterystyce ph.ecog=1 i ph.karno=90



Rysunek 12: Porównanie oszacowań funkcji przeżycia w modelach PH oraz Cox PH na danych lung, dla kobiety w wieku 70 lat o charakterystyce ph.ecog=1 i ph.karno=90

Na podstawie powyższego wykresu 12, możemy stwierdzić, że krzywa funkcji Cox PH oraz krzywa funkcji PH pokrywają się niemal na każdym etapie obserwowanego czasu. Zatem możemy wnioskować, że oba model dobrze “radzą” sobie z danymi.

3 Lista 11

3.1 Zadanie 1

Model proporcjonalnych szans jest postaci

$$\theta_z(t) = \theta_0(t) \exp(\beta^T z) = \frac{1 - S_0(t)}{S_0(t)} \exp(\beta^T z).$$

Za zmienne przyjmujemy age, sex, ph.ecog oraz ph.karno i korzystamy z funkcji prop.ods() z pakietu timereg.

```
model_PS = prop.ods(Event(time, status == 2) ~
  sex +
  age +
  ph.ecog +
  ph.karno,
  data = data,
  n.sim = 10000)
```

Nasza β znajduje się w tym obiekcie pod nazwą *gamma*.

```
beta = model_PS$gamma
beta
```

```
##           estimate
## sex2      -0.953708712
## age       0.013236425
## ph.ecog1  0.546678169
## ph.ecog2  1.447437371
## ph.ecog3  1.924432367
## ph.karno  -0.003701666
```

Odczytujemy, że z dokładnością do dwóch cyfr znaczących:

$$\beta^T = (-0.95, 0.013, 0.55, 1.4, 1.9, -0.0037)$$

3.2 Zadanie 2

Ze znaków w wektorze β odczytujemy, że:

- Kobiety oraz pacjenci z wysokim ph.karno mają dłuższe czasy życia.
- Podeszły wiek oraz wysokie ph.ecog skracają czas życia.

Tym razem nie obserwujemy, aby ph.karno skracał czas życia co wydaje się być poprawnym zachowaniem. Współczynniki dla ph.karno oraz wieku mają niskie wartości.

O naszym modelu możemy powiedzieć, że logarytm ilorazu szans w chwili t , dla dwóch jednostek o wektorach charakterystyk z_1, z_2 , jest postaci:

$$\ln\left(\frac{\theta_{z_1}(t)}{\theta_{z_2}(t)}\right) = \beta^T(z_1 - z_2).$$

3.3 Zadanie 3

Odczytuję z modelu czasy zdarzeń oraz odpowiadające im bazowe ilorazy szans θ_0 .

```
times = model_PS$cum[,1]
theta0 = model_PS$cum[,2]
```

Odczytuję bazową funkcję przeżycia S_0 .

```
pred0 = predict(model_PS,
                 Z = c(0, 0, 0, 0, 0, 0))

S0 = as.numeric(pred0$S0)
head(signif(S0,3))
```

```
## [1] 1.000 0.997 0.995 0.992 0.989 0.986
```


Aby wyznaczyć skumulowaną funkcję hazardu H_0 korzystam z zależności

$$H(t) = -\ln(S(t)).$$

```
H0 = -log(S0)
head(signif(H0, 3))
```

```
## [1] 0.00000 0.00267 0.00535 0.00808 0.01080 0.01360
```

Na wykresie 13 znajdziemy oszacowanie bazowych funkcji przeżycia i skumulowanego hazardu.



Rysunek 13: Oszacowanie bazowych funkcji przeżycia i skumulowanego hazardu w modelu proporcjonalnych szans

3.4 Zadanie 4

Aby wyznaczyć skumulowane funkcje hazardu dla poszczególnych jednostek korzystamy z tego, że

$$S_z(t) = \frac{1}{1 + \theta_0(t) \exp(\beta^T z)}$$

oraz

$$H(t) = -\ln(S).$$

```


S_z1 = 1/(1 + theta0*exp(sum(beta*z1)))
S_z2 = 1/(1 + theta0*exp(sum(beta*z2)))

H_z1 = -log(S_z1)
H_z2 = -log(S_z2)

```

Na wykresie 14 znajdują się skumulowane funkcje hazardu i logarytmy skumulowanej funkcji hazardu dla 70 letniej kobiety z $ph.karno=90$. Zgodnie z interpretacją skali $ph.ecog$ obserwujemy, że dla wyższej wartości tego współczynnika mamy krótsze czasu życia, czyli wyższe wartości skumulowanej funkcji hazardu. Porównując z modelem proporcjonalnych hazardów Coxa, widzimy że dla $ph.ecog=2$ skumulowana funkcja hazardu ma widocznie mniejsze wartości. Opuszczenie założenia o proporcjonalności hazardów spowodowało, że logarytmy skumulowanych funkcji różnią się od siebie bardziej niż przesunięciem o stałą.

Wykresy skumulowanej funkcji hazardu i logarytmu skumulowanej funkcji hazardu dla 70 letniej kobiety z $ph.karno=90$



Rysunek 14: Wykresy skumulowanej funkcji hazardu i logarytmu skumulowanej funkcji hazardu dla 70 letniej kobiety z $ph.karno=90$

3.5 Zadanie 5

Oszacowanie funkcji przeżycia wyznaczyliśmy już na potrzeby zadania 4. Za ich pomocą odczytujemy szacowane prawdopodobieństwa przeżycia 300 dni:

```
P1 = S_z1[max(which(times<=300))]  
P2 = S_z2[max(which(times<=300))]
```

```
P1
```

```
## [1] 0.6750321
```

```
P2
```


```
## [1] 0.4576702
```

Dla $ph.ecog=1$ wynosi ono ok 0.67, a dla $ph.ecog=2$ 0.46. Wynik jest zgodny z intuicją tzn. pacjent w gorszym stanie zdrowia ma mniejsze prawdopodobieństwo przeżycia 300 dni. W zadaniu 5 z listy 10 wynosiły one ok. 0.59 i 0.36, czyli wyraźnie mniej niż dla modelu proporcjonalnych szans.

3.6 Zadanie 6

Na wykresie 15 widzimy funkcje przeżycia dla 70 letniej kobiety z $ph.karno=90$ i $ph.ecog=1$ dla modeli proporcjonalnych szans oraz proporcjonalnych hazardów Coxa. Jak widzimy funkcja przyjmuje wyższe wartości w modelu proporcjonalnych szans, czyli przewiduje dłuższe czasy życia.

Wykresy szacowanej funkcji przeżycia dla 70 letniej kobiety z $ph.karno=90$ i $ph.ecog=1$ dla modeli proporcjonalnych szans oraz proporcjonalnych hazardów Coxa



Rysunek 15: Wykresy funkcji przeżycia dla 70 letniej kobiety z $ph.karno=90$ i $ph.ecog=1$ dla modeli proporcjonalnych szans oraz proporcjonalnych hazardów Coxa

4 Lista 12

4.1 Zadanie 1

W poniższych podpunktach przyjmuje model przyspieszonego czasu awarii, w którym bazowa funkcja przeżycia odpowiada rozkładowi Weibulla, przyjmując za zmienną zależną zmienną *time*, a za charakterystyki zmienne: *age*, *sex*, *ph.ecog*, *ph.karno*.

```
model.walda<-survreg(Surv(time,status==2)~sex+age+ph.ecog+ph.karno,data=data,dist="weibull")
```

4.1.1 a)

Test Walda

Korzystamy z testu Walda, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *age* nie jest istotna w przyjętym modelu.

```
round(summary(model.walda)[["table"]][,4], 5)
```

Tabela 5: Wartości p dla poszczególnych zmiennych

Zmienne	Wartości p
sex2	0.00091
age	0.20530
ph.ecog1	0.01191
ph.ecog2	0.00023
ph.ecog3	0.02788
ph.karno	0.13792

Z powyższego podsumowania 5 wynika, że korzystając z testu Walda, na poziomie istotności 0.05, nie mamy podstaw do odrzucenia hipotezy, że zmienna *age* nie jest istotna w przyjętym modelu. Wartość p w tym teście jest równa około 0.20530.

Test IW

Model bez zmiennej *age*, wykorzystywany do konstrukcji testu IW.

```
model.IW<-survreg(Surv(time,status==2)~sex+ph.ecog+ph.karno, data=data, dist ="weibull")
```

Korzystamy z testu IW, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *age* nie jest istotna w przyjętym modelu

```
anova(model.IW,model.walda)$`Pr(>Chi)`[2]
```

Wartość p w tym teście jest równa 0.2013662. Z powyższej informacji wynika, że korzystając z testu IW, na poziomie istotności 0.05, nie mamy podstaw do odrzucenia hipotezy, że zmienna *age* nie jest istotna w przyjętym modelu.

4.1.2 b)

Test Walda

Korzystamy z testu Walda na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *sex* nie jest istotna w przyjętym modelu.

```
round((summary(model.walda)[["table"]][,4]), 5)
```

Tabela 6: Wartości p dla poszczególnych zmiennych

Zmienne	Wartości p
sex2	0.00091
age	0.20530
ph.ecog1	0.01191
ph.ecog2	0.00023
ph.ecog3	0.02788
ph.karno	0.13792

Z powyższego podsumowania 6 wynika, że korzystając z testu Walda, na poziomie istotności należy odrzucić hipotezę, że zmienna *sex* nie jest istotna w przyjętym modelu. Wartość p w tym teście jest równa 0.00091.

Test IW

Model bez zmiennej *sex*, wykorzystywany do konstrukcji testu IW.

```
model.IW<-survreg(Surv(time,status==2)~age+ph.ecog+ph.karno, data=data, dist ="weibull")
```

Korzystamy z testu IW, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *sex* nie jest istotna w przyjętym modelu

```
anova(model.IW,model.walda)$`Pr(>Chi)`[2]
```

Wartość p w tym teście jest równa 0.0005958668. Z powyższej informacji wynika, że korzystając z testu IW, na poziomie istotności 0.05, powinniśmy odrzucić hipotezę, że zmienna *sex* nie jest istotna w przyjętym modelu.

4.1.3 c)

Test IW

Korzystamy z testu IW - ilorazu wiarygodności, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że rozkład czasu życia jest taki sam dla pacjenta o sprawności ECOG wg. lekarza na poziomie 0, 1, 2, 3 (zmienna *ph.ecog* teoretycznie może przyjmować wartości 0, 1, 2, 3, 4, 5, ale w zbiorze danych mamy tylko wartości od 0 do 3).

Model bez zmiennej *ph.ecog*, wykorzystywany do konstrukcji testu IW.

```
model.IW<-survreg(Surv(time,status==2)~sex+age+ph.karno, data=data, dist ="weibull")
```

```
anova(model.IW,model.walda)$`Pr(>Chi)`[2]
```

Wartość p w tym teście jest równa 0.0021387. Z powyższej informacji wynika, że korzystając z testu IW, na poziomie istotności 0.05, powinniśmy odrzucić hipotezę, że rozkład czasu życia jest taki sam dla pacjenta o sprawności ECOG wg. lekarza na poziomie 0, 1, 2, 3. Możemy zatem wywnioskować, że przynajmniej jeden z poziomów ECOG różni się istotnie pod względem rozkładu czasu życia pacjenta.

4.2 Zadanie 2

W poniższych podpunktach przyjmuje model proporcjonalnych hazardów Coxa, przyjmując za zmienną zależną zmienną *time*, a za charakterystyki zmienne: *age*, *sex*, *ph.ecog*, *ph.karno*.

```
model.cox<-coxph(formula=Surv(time,status==2)~age+sex+ ph.ecog+ph.karno, data=data)
```

4.2.1 a)

Test Walda

Korzystamy z testu Walda, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *age* nie jest istotna w przyjętym modelu.

```
round((summary(model.cox)$coefficients[, "Pr(>|z|)"]), 6)
```

Tabela 7: Wartości p dla poszczególnych zmiennych

Zmienne	Wartości p
age	0.183903
sex2	0.000861
ph.ecog1	0.014474
ph.ecog2	0.000484
ph.ecog3	0.026699
ph.karno	0.195118

Z powyższego podsumowania 7 wynika, że korzystając z testu Walda, na poziomie istotności 0.05, nie mamy podstaw do odrzucenia hipotezy, że zmienna *age* nie jest istotna w przyjętym modelu. Wartość p w przybliżeniu do 5 cyfr po przecinku w tym teście jest równa 0.183903.

Test IW

Model bez zmiennej *age*, wykorzystywany do konstrukcji testu IW.

```
model.IW<-coxph(formula=Surv(time,status==2)~sex+ ph.ecog+ph.karno, data=data)
```

Korzystamy z testu IW, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *age* nie jest istotna w przyjętym modelu.

```
anova(model.IW,model.cox)$`Pr(>|Chi|)`[2]
```

Wartość p w tym teście jest równa 0.1803751. Z powyższej informacji wynika, że korzystając z testu IW, na poziomie istotności 0.05, nie mamy podstaw do odrzucenia hipotezy, że zmienna *age* nie jest istotna w przyjętym modelu.

4.2.2 b)

Test Walda

Korzystamy z testu Walda na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *sex* nie jest istotna w przyjętym modelu.

```
round((summary(model.cox)$coefficients[, "Pr(>|z|)"], 6)
```

Zmienne	Wartości p
age	0.183903
sex2	0.000861
ph.ecog1	0.014474
ph.ecog2	0.000484
ph.ecog3	0.026699
ph.karno	0.195118

Z powyższego podsumowania wynika, że korzystając z testu Walda, na poziomie istotności należy odrzucić hipotezę, że zmienna *sex* nie jest istotna w przyjętym modelu. Wartość p w tym teście jest równa 0.000861.

Test IW

Model bez zmiennej *sex*, wykorzystywany do konstrukcji testu IW.

```
model.IW<-coxph(formula=Surv(time,status==2)~age+ ph.ecog+ph.karno, data=data)
```

Korzystamy z testu IW, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że zmienna *sex* nie jest istotna w przyjętym modelu

```
anova(model.IW,model.cox)$`Pr(>|Chi|)`[2]
```

Wartość p w tym teście jest równa 0.000628618. Z powyższej informacji wynika, że korzystając z testu IW, na poziomie istotności 0.05, powinniśmy odrzucić hipotezę, że zmienna *sex* nie jest istotna w przyjętym modelu.

4.2.3 c)

Test IW

Korzystamy z testu IW - ilorazu wiarygodności, na poziomie istotności 0.05. Moją hipotezą do zweryfikowania jest stwierdzenie, że rozkład czasu życia jest taki sam dla pacjenta o sprawności ECOG wg. lekarza na poziomie 0, 1, 2, 3 (zmienna *ph.ecog* teoretycznie może przyjmować wartości 0, 1, 2, 3, 4, 5, ale w zbiorze danych mamy tylko wartości od 0 do 3).

Model bez zmiennej *ph.ecog*, wykorzystywany do konstrukcji testu IW.

```
model.IW<-coxph(formula=Surv(time,status==2)~age+sex+ph.karno, data=data)
```

```
anova(model.IW,model.cox)$`Pr(>|Chi|)`[2]
```

Wartość p w tym teście jest równa 0.0036483. Z powyższej informacji wynika, że korzystając z testu IW, na poziomie istotności 0.05, powinniśmy odrzucić hipotezę, że rozkład czasu życia jest taki sam dla pacjenta o sprawności ECOG wg. lekarza na poziomie 0, 1, 2, 3. Możemy zatem wywnioskować, że przynajmniej jeden z poziomów ECOG różni się istotnie pod względem rozkładu czasu życia pacjenta.

5 Zadania dodatkowe

5.1 Zadanie 3 z listy 12

W poniższych podpunktach przyjmuje model przyspieszonego czasu awarii, w którym bazowa funkcja przeżycia odpowiada rozkładowi Weibulla, przyjmując za zmienną zależną zmienną *time*, a za charakterystyki zmienne: *age*, *sex*, *ph.ecog*, *ph.karno*.

```
model.walda<-survreg(Surv(time,status==2)~sex+age+ph.ecog+ph.karno, data=data, dist ="weibull")
```

5.1.1 a)

Korzystam z metody eliminacji. Weryfikuję hipotezę (4 hipotezy), że współczynnik przy danej zmiennej jest równy zero (dana zmienna nie jest istotna w modelu). Z modelu usuwam zmienną, dla której wartość p-value w teście jest największa i większa od przyjętego poziomu istotności (0.05), Powtarzam powyższą czynność (algorytm) do momentu, aż nie będzie już zmiennych, które można by było usunąć tzn. ich p-value będzie mniejsze od poziomu istotności.

```
drop1(model.walda, test = "Chisq")
```

Tabela 9: Wartości p dla zmiennych

Zmienne	Wartość p
sex	0.0006
age	0.2014
ph.ecog	0.0021
ph.karno	0.1332

Na podstawie tabeli 9 największą wartość p-value w zaokrągleniu do 4 miejsc po przecinku otrzymaliśmy dla zmiennej *age*. Na podstawie powyższego testu nie mam podstaw do odrzucenia hipotezy, że zmienna *age* jest nieistotna, p-value testu IW zmiennej *age* wyniosło $0.2014 > 0.05$. Zatem usuwam zmienną *age* z naszego modelu.

Model bez zmiennej *age* (usunięta).

```
model.walda<-survreg(Surv(time,status==2)~sex+ph.ecog+ph.karno, data=data, dist ="weibull")
```

```
drop1(model.walda, test = "Chisq")
```

Tabela 10: Wartości p dla zmiennych

Zmienne	Wartość p
sex	0.0007
ph.ecog	0.0020
ph.karno	0.1756

Na podstawie tabeli 10 dla modelu bez zmiennej *age* największą wartość $p = 0.1756$, większą od poziomu istotności $\alpha = 0.05$, otrzymujemy dla testu IW zmiennej *ph.karno*. Zatem nie mam podstaw do odrzucenia hipotezy, że zmienna *ph.karno* jest nieistotna. Zatem usuwam zmienną *ph.karno* z naszego modelu.

Model bez zmiennej *ph.karno* (usunięta).

```
model.walda<-survreg(Surv(time,status==2)~sex+ph.ecog, data=data, dist ="weibull")
```

```
drop1(model.walda, test = "Chisq")
```

Tabela 11: Wartości p dla zmiennych

Zmienne	Wartość p
sex	0.0011
ph.ecog	0.0004

Analizując powyższe wartości p w tabeli 11 (są one mniejsze od zadanego poziomu istotności) odrzucamy hipotezę o tym, że zmienne *sex*, *ph.ecog* są nieistotne.

Nasz model ma ostateczną postać

```
model.walda<-survreg(Surv(time,status==2)~sex+ph.ecog, data=data, dist ="weibull")
```

Tabela 12: Współczynniki modelu

Wartości współczynników modelu	
sex2	0.390
ph.ecog1	-0.296
ph.ecog2	-0.679
ph.ecog3	-1.420

Na podstawie tabeli 12 i postaci założonego modelu przyspieszonych awarii wnioskujemy, że pacjenci o charakterystyce $sex = 2$ żyją średnio dłużej, niż pacjenci z grupy bazowej, gdy pozostałe zmienne są stałe. Każdy z 3 współczynników $ph.ecog1$, $ph.ecog2$, $ph.ecog3$ wskazuje, że pacjenci z niższym stanem sprawności, mają krótsze przeżycie, niż pacjenci ze stanem $ph.ecog = 0$.

5.1.2 b)

Korzystam z kryterium informacyjnego Akaike'a (AIC).

```
model.walda<-survreg(Surv(time,status==2)~sex+age+ph.ecog+ph.karno, data=data, dist ="weibull")
```

```
AIC<-step(model.walda,direction = "backward",k=2)
```

```
## Start:  AIC=2266.6
## Surv(time, status == 2) ~ sex + age + ph.ecog + ph.karno
##
##           Df    AIC
## - age      1 2266.2
## <none>      2266.6
## - ph.karno  1 2266.8
## - ph.ecog   3 2275.2
## - sex       1 2276.4
##
## Step:  AIC=2266.23
## Surv(time, status == 2) ~ sex + ph.ecog + ph.karno
##
##           Df    AIC
## - ph.karno  1 2266.1
## <none>      2266.2
## - ph.ecog   3 2275.0
## - sex       1 2275.8
##
## Step:  AIC=2266.07
## Surv(time, status == 2) ~ sex + ph.ecog
##
##           Df    AIC
## <none>      2266.1
## - sex      1 2274.7
## - ph.ecog  3 2278.4
```


Najmniejszą wartość AIC otrzymujemy dla modelu:

```
model.walda<-survreg(Surv(time,status==2)~sex+ph.ecog, data=data, dist ="weibull")
```

po usunięciu z niego zmiennej *age* i *ph.karno*. Usunięcie zmiennych *sex* lub *ph.ecog* powodowało wzrost wartości AIC (gorsze dopasowanie modelu).

Zatem model nasz końcowy ma postać jak powyższy.

Tabela 13: Współczynniki modelu

Wartości współczynników modelu	
sex2	0.390
ph.ecog1	-0.296
ph.ecog2	-0.679
ph.ecog3	-1.420

Na podstawie tabeli 13 i postaci założonego modelu przyspieszonych awarii wnioskujemy, że pacjenci o charakterystyce *sex* = 2 żyją średnio dłużej, niż pacjenci z grupy bazowej, gdy pozostałe zmienne są stałe. Każdy z 3 współczynników *ph.ecog1*, *ph.ecog2*, *ph.ecog3* wskazuje, że pacjenci z niższym stanem sprawności, mają krótsze przeżycie, niż pacjenci ze stanem *ph.ecog* = 0.

5.1.3 c)

Korzystam z kryterium informacyjnego (BIC).

```
model.walda<-survreg(Surv(time,status==2)~sex+age+ph.ecog+ph.karno, data=data, dist ="weibull")
n<-nrow(data[complete.cases(data), ])
BIC<-step(model.walda,direction = "backward",k=log(n))
```

```
## Start:  AIC=2293.96
## Surv(time, status == 2) ~ sex + age + ph.ecog + ph.karno
##
##           Df    AIC
## - age      1 2290.2
## - ph.karno  1 2290.8
## - ph.ecog   3 2292.3
## <none>      2294.0
## - sex      1 2300.3
##
## Step:  AIC=2290.17
## Surv(time, status == 2) ~ sex + ph.ecog + ph.karno
##
##           Df    AIC
## - ph.karno  1 2286.6
## - ph.ecog   3 2288.7
## <none>      2290.2
## - sex      1 2296.4
##
```

```
## Step: AIC=2286.59
## Surv(time, status == 2) ~ sex + ph.ecog
##
##           Df      AIC
## <none>      2286.6
## - ph.ecog  3 2288.6
## - sex      1 2291.8
```

Najmniejszą wartość BIC otrzymujemy dla modelu:

```
model.walda<-survreg(Surv(time,status==2)~sex+ph.ecog, data=data, dist ="weibull")
```

po usunięciu z niego zmiennej *age* i *ph.karno*. Usunięcie zmiennych *sex* lub *ph.ecog* powodowało wzrost wartości BIC (gorsze dopasowanie modelu).

Zatem model nasz końcowy ma postać jak powyższy.

Tabela 14: Współczynniki modelu

Wartości współczynników modelu	
sex2	0.390
ph.ecog1	-0.296
ph.ecog2	-0.679
ph.ecog3	-1.420

Na podstawie tabeli 14 i postaci założonego modelu przyspieszonych awarii wnioskujemy, że pacjenci o charakterystyce *sex* = 2 żyją średnio dłużej, niż pacjenci z grupy bazowej, gdy pozostałe zmienne są stałe. Każdy z 3 współczynników *ph.ecog1*, *ph.ecog2*, *ph.ecog3* wskazuje, że pacjenci z niższym stanem sprawności, mają krótsze przeżycie, niż pacjenci ze stanem *ph.ecog* = 0.

5.2 Zadanie 4 z listy 12

W poniższych podpunktach przyjmuje model proporcjonalnych hazardów Coxa ze zmienną zależną zmienną *time*, a za charakterystyki zmienne: *age*, *sex*, *ph.ecog*, *ph.karno*.

```
model.cox<-coxph(formula=Surv(time,status==2)~age+sex+ ph.ecog+ph.karno, data=data)
```

5.2.1 a)

Korzystam z metody eliminacji. Weryfikuję hipotezę (4 hipotezy), że współczynnik przy danej zmiennej jest równy zero (dana zmienna nie jest istotna w modelu). Z modelu usuwam zmienną, dla której wartość p-value w teście jest największa i większa od przyjętego poziomu istotności (0.05), Powtarzam powyższą czynność (algorytm) do momentu, aż nie będzie już zmiennych, które można by było usunąć tzn. ich p-value będzie mniejsze od poziomu istotności.

```
drop1(model.cox, test = "Chisq")
```

Tabela 15: Wartości p dla zmiennych

Zmienne	Wartość p
age	0.1804
sex	0.0006
ph.ecog	0.0036
ph.karno	0.1886

Na podstawie tabeli 15 największą wartość p-value otrzymaliśmy dla zmiennej *ph.karno*. Na podstawie powyższego testu nie mam podstaw do odrzucenia hipotezy, że zmienna *ph.karno* jest nieistotna, p-value testu IW zmiennej *ph.karno* wyniosło $0.1886 > 0.05$. Zatem usuwam zmienną *ph.karno* z naszego modelu.

Model bez zmiennej *ph.karno* (usunięta).

```
model.cox<-coxph(formula=Surv(time,status==2)~age+sex+ ph.ecog, data=data)
```

```
drop1(model.cox, test = "Chisq")
```

Tabela 16: Wartości p dla zmiennych

Zmienne	Wartość p
age	0.2343
sex	0.0010
ph.ecog	0.0010

Na podstawie tabeli 16 dla modelu bez zmiennej *ph.karno* największą wartość $p = 0.2343$, większą od poziomu istotności $\alpha = 0.05$, otrzymujemy dla testu IW zmiennej *age*. Zatem nie mam podstaw do odrzucenia hipotezy, że zmienna *age* jest nieistotna. Zatem usuwam zmienną *age* z naszego modelu.

Model bez zmiennej *age* (usunięta).

```
model.cox<-coxph(formula=Surv(time,status==2)~sex+ ph.ecog, data=data)
```

```
drop1(model.cox, test = "Chisq")
```

Tabela 17: Wartości p dla zmiennych

Zmienne	Wartość p
sex	1e-03
ph.ecog	4e-04

Analizując powyższe wartości p w tabeli 17 (są one mniejsze od zadanego poziomu istotności) odrzucamy hipotezę o tym, że zmienne *sex*, *ph.ecog* są nieistotne.

Nasz model ma ostateczną postać

```
model.cox<-coxph(formula=Surv(time,status==2)~sex+ ph.ecog, data=data)
```

Tabela 18: Współczynniki modelu

Wartości współczynników modelu	
sex2	-0.539
ph.ecog1	0.419
ph.ecog2	0.931
ph.ecog3	2.069

Na podstawie tabeli 18 i postaci założonego modelu proporcjonalnych hazardów Coxa wnioskujemy, że pacjenci o charakterystyce $sex = 2$ mają niższe ryzyko zgonu, niż pacjenci z grupy bazowej, gdy pozostałe zmienne są stałe. Każdy z 3 współczynników $ph.ecog1$, $ph.ecog2$, $ph.ecog3$ wskazuje, że pacjenci z niższym stanem sprawności, mają wyższe ryzyko zgonu, niż pacjenci ze stanem $ph.ecog = 0$.

5.2.2 b)

Korzystam z kryterium informacyjnego Akaike'a (AIC).

```
model.cox<-coxph(formula=Surv(time,status==2)~age+sex+ ph.ecog+ph.karno, data=data)
AIC<-step(model.cox,direction = "backward",k=2)
```

```
## Start:  AIC=1458.54
## Surv(time, status == 2) ~ age + sex + ph.ecog + ph.karno
##
##           Df    AIC
## - ph.karno  1 1458.3
## - age       1 1458.3
## <none>      1458.5
## - ph.ecog   3 1466.0
## - sex       1 1468.2
##
## Step:  AIC=1458.27
## Surv(time, status == 2) ~ age + sex + ph.ecog
##
##           Df    AIC
## - age       1 1457.7
## <none>      1458.3
## - sex       1 1467.0
## - ph.ecog   3 1468.5
##
## Step:  AIC=1457.68
## Surv(time, status == 2) ~ sex + ph.ecog
##
##           Df    AIC
## <none>      1457.7
## - sex       1 1466.5
## - ph.ecog   3 1470.1
```

Najmniejszą wartość AIC otrzymujemy dla modelu:

```
model.cox<-coxph(formula=Surv(time,status==2)~sex+ ph.ecog, data=data)
```

po usunięciu z niego zmiennej *age* i *ph.karno*. Usunięcie zmiennych *sex* lub *ph.ecog* powodowało wzrost wartości AIC (gorsze dopasowanie modelu).

Zatem model nasz końcowy ma postać jak powyższy.

Tabela 19: Współczynniki modelu

Wartości współczynników modelu	
sex2	-0.539
ph.ecog1	0.419
ph.ecog2	0.931
ph.ecog3	2.069

Na podstawie tabeli 19 i postaci założonego modelu proporcjonalnych hazardów Coxa wnioskujemy, że pacjenci o charakterystyce *sex* = 2 mają niższe ryzyko zgonu, niż pacjenci z grupy bazowej, gdy pozostałe zmienne są stałe. Każdy z 3 współczynników *ph.ecog1*, *ph.ecog2*, *ph.ecog3* wskazuje, że pacjenci z niższym stanem sprawności, mają wyższe ryzyko zgonu, niż pacjenci ze stanem *ph.ecog* = 0.

5.2.3 c)

Korzystam z kryterium informacyjnego (BIC).

```
model.cox<-coxph(formula=Surv(time,status==2)~age+sex+ ph.ecog+ph.karno, data=data)

n<-nrow(data[complete.cases(data), ])

BIC<-step(model.cox,direction = "backward",k=log(n))
```

```
## Start:  AIC=1479.06
## Surv(time, status == 2) ~ age + sex + ph.ecog + ph.karno
##
##           Df    AIC
## - ph.karno  1 1475.4
## - age       1 1475.4
## - ph.ecog   3 1476.3
## <none>      1479.1
## - sex       1 1485.3
##
## Step:  AIC=1475.37
## Surv(time, status == 2) ~ age + sex + ph.ecog
##
##           Df    AIC
## - age       1 1471.4
## <none>      1475.4
## - ph.ecog   3 1475.4
## - sex       1 1480.7
##
## Step:  AIC=1471.36
## Surv(time, status == 2) ~ sex + ph.ecog
```

```
##
##           Df      AIC
## <none>      1471.4
## - ph.ecog  3 1473.6
## - sex      1 1476.7
```

Najmniejszą wartość BIC otrzymujemy dla modelu:

```
model.cox<-coxph(formula=Surv(time,status==2)~sex+ ph.ecog, data=data)
```

po usunięciu z niego zmiennej *age* i *ph.karno*. Usunięcie zmiennych *sex* lub *ph.ecog* powodowało wzrost wartości BIC (gorsze dopasowanie modelu).

Zatem model nasz końcowy ma postać jak powyższy.

Tabela 20: Współczynniki modelu

Wartości współczynników modelu	
sex2	-0.539
ph.ecog1	0.419
ph.ecog2	0.931
ph.ecog3	2.069

Na podstawie tabeli 20 i postaci założonego modelu proporcjonalnych hazardów Coxa wnioskujemy, że pacjenci o charakterystyce *sex* = 2 mają niższe ryzyko zgonu, niż pacjenci z grupy bazowej, gdy pozostałe zmienne są stałe. Każdy z 3 współczynników *ph.ecog1*, *ph.ecog2*, *ph.ecog3* wskazuje, że pacjenci z niższym stanem sprawności, mają wyższe ryzyko zgonu, niż pacjenci ze stanem *ph.ecog* = 0.

5.3 Zadanie dodatkowe z listy 12

Funkcja *fic.coxph()* nie jest dostępna dla użytkownika, używamy jej poprzez wywołanie *fic()* na modelu *coxph()*. Niestety próba wywołania funkcji *fic()* tak aby sprawdzała wszystkie możliwe modele kończy się błędem tzn. wektor *inds0_terms* nie może zawierać samych zer. Wiedząc, że zmienna *sex* jest ważnym czynnikiem w określaniu prawdopodobieństwa przeżycia oznaczamy ją jako zawsze obecną w modelu. Konieczne jest ustalenie dla jakiej jednostki obliczamy błąd. W tym zadaniu będzie to mężczyzna z *ph.ecog*=1 o uśrednionych *age* oraz *ph.karno*.

```
wide <- coxph(Surv(time, status == 2) ~
              age +
              sex +
              ph.ecog +
              ph.karno, data)

inds0_terms <- c(0, 1, 0, 0)

inds0 <- expand_inds(inds0_terms, wide)

combs <- all_inds(wide, inds0)

newdata <- data.frame(
  age = mean(data$age),
```

```

sex = factor(1, levels = levels(data$sex)),
ph.ecog = factor(1, levels = levels(data$ph.ecog)),
ph.karno = mean(data$ph.karno)
)
X <- newdata_to_X(newdata, wide, intercept = FALSE)

fic_hr <- fic(wide, inds = combs, inds0 = inds0, focus = "hr", X = X, t = 10)

fic_survival <- fic(wide, inds = combs, inds0 = inds0, focus = "survival", X = X, t = 365)

fic_cumhaz <- fic(wide, inds = combs, inds0 = inds0, focus = "cumhaz", X = X, t = 365)

fic_hr = as.character(fic_hr[which.min(fic_hr$FIC),]$mods)
fic_survival = as.character(fic_survival[which.min(fic_survival$FIC),]$mods)
fic_cumhaz = as.character(fic_cumhaz[which.min(fic_cumhaz$FIC),]$mods)

```

Parametr *hr* oznacza błąd w oszacowaniu ryzyka względem bazowego hazardu

```
fic_hr
```

```
## [1] "0110"
```

Odczytujemy że optymalny w tym sensie model składa się ze zmiennych *sex* oraz *ph.ecog*. Wyznaczamy parametry:

```
coxph(Surv(time, status == 2) ~
      sex +
      ph.ecog, data)$coef
```

```
##      sex2    ph.ecog1    ph.ecog2    ph.ecog3
## -0.5387885  0.4186114  0.9314840  2.0689288
```

Odczytujemy, że wysokie *ph.ecog* skraca życie, a bycie kobietą wydłuża.

Parametr *survival* oznacza błąd w oszacowaniu funkcji przeżycia w wybranym przez nas punkcie $t = 365$.

```
fic_survival
```

```
## [1] "1100"
```

Odczytujemy że optymalny w tym sensie model składa się jedynie ze zmiennej *age* oraz *sex*.

```
coxph(Surv(time, status == 2) ~
      age +
      sex, data)$coef
```

```
##      age      sex2
## 0.01743209 -0.49848484
```

Odczytujemy, że bycie kobietą wydłuża czas życia, a podeszły wiek skraca.

Parametr *cumhaz* oznacza błąd w oszacowaniu skumulowanej funkcji hazardu w wybranym przez nas punkcie $t = 365$.

```
fic_cumhaz
```

```
## [1] "0110"
```

Odczytujemy że optymalny w tym sensie model jest taki sam jak dla parametru *survival*.

5.4 Zadanie dodatkowe z dodatkowej listy

5.4.1 Zadanie 1

Zakładamy że nasze dane są postaci (x_i, y_i) . Definiujemy statystykę

$$C = \frac{c + 0.5t_x}{c + d + t_x},$$

Gdzie:

- c - liczba par $(x_i, y_i), (x_j, y_j)$, że $x_i < x_j$ i $y_i < y_j$ lub $x_i > x_j$ i $y_i > y_j$
- d - liczba par $(x_i, y_i), (x_j, y_j)$, że $x_i < x_j$ i $y_i > y_j$ lub $x_i > x_j$ i $y_i < y_j$
- t_x - liczba par $(x_i, y_i), (x_j, y_j)$, $x_i = x_j$ i $y_i \neq y_j$

Nasza statystyka C jest oszacowaniem $P(x_i > x_j | y_i > y_j)$ lub równoważnie $P(y_i > y_j | x_i > x_j)$. W definicji tej statystyki pomijamy dane dla który $y_i = y_j$, ponieważ takie obserwacje nie wnoszą nam istotnych informacji o poprawności modelu, natomiast zakładamy, że jeżeli $x_i = x_j$ to w połowie przypadków poprawnie uporządkujemy y_i oraz y_j , stąd $0.5t_x$.

C dla modelu AFT z zadania 1:

```
concordance(model.walda)$concordance
```

```
## [1] 0.6397352
```

C dla modelu proporcjonalnych hazardów Coxa z zadania 2:

```
concordance(model.cox)$concordance
```

```
## [1] 0.6397352
```

Wartości statystyki C dla modelu przyspieszonego czasu awarii i proporcjonalnych hazardów Coxa wynoszą odpowiednio ok. 0.64 i 0.633. W naszych modelach rolę x_i pełni (prawdopodobnie bo dokumentacja funkcji `concordance()` tego nie precyzuje) $-\beta^T z_i$, a y_i jest czasem życia. Pamiętając, że $C \approx P(y_i > y_j | x_i > x_j)$, od lepszego modelu spodziewalibyśmy się wyższej wartości tej statystyki. W naszym wypadku różnica jest zbyt mała aby uznać któryś z modeli za bardziej odpowiedni.